

Onderzoeksrapport *Foto van Vlaanderen*

Prof. Dr. Freek Van de Velde (KU Leuven)

31 mei 2026

0 Inleiding

In dit rapport wordt een statistische analyse uitgevoerd op de ruwe data van het onderzoek *Foto van Vlaanderen 2025*. De data zijn door de VRT beschikbaar gesteld op <https://www.vrt.be/nl/over-ons/nieuws-over-vrt/de-foto-van-vlaanderen-relevant-en-correct-onderzoek>. De dataverwerking en -kwaliteitscontrole is uitgevoerd door het marketing- en onderzoeksbureau *Profacts*.

Ik ga in dit rapport in het bijzonder in op de relatie tussen een aantal socio-demografische variabelen (opleidingsniveau, leeftijd, geslacht en herkomstregio) en een aantal stellingen die gaan over gender-gerelateerde issues. Die laatste worden gebruikt als responsvariabele. De volledige dataset bevat veel meer gegevens, omdat er ook gepeild is naar andere kwesties, zoals familiaal of maatschappelijk geluksgevoel, gezondheid, koopkracht en armoede, misdaad en straf, en overheid en democratie. Die worden in dit rapport buiten beschouwing gelaten, niet omdat die oninteressant zouden zijn, maar omdat zich in de klassieke en op de sociale media een discussie ontsponnen heeft over de gender-issues, en in het bijzonder over de rol van de variabele herkomstregio. Wat hierdoor onvermijdelijk buiten beschouwing blijft in dit rapport, zijn overwegingen over de relatie tussen de gender-gerelateerde responsvariabelen en de andere variabelen.

In dit rapport wordt gebruik gemaakt van een aantal methoden uit de inferentiële statistiek. Die methoden kunnen een inschatting geven van effectgroottes en significantie van associaties tussen variabelen, en op die manier een onderscheid maken tussen ‘signaal’ en ‘ruis’. Wat ze niet kunnen is het aannemelijk maken van verklaringen achter de associaties, van causale verbanden tussen de variabelen, en van effecten die niet gemeten zijn. Het rapport vertrekt van een zogenoemde frequentistische benadering, en zal de Bayesiaanse aanpak buiten beschouwing laten. Het oogmerk van dit rapport is een eerlijke rapportage, waarbij de data maximaal benut worden. Voor de analyse is gebruik gemaakt van het programma R (versie 4.2.1), met de pakketten *dplyr* (Wickham et al. 2023), *psych* (Revelle 2026), *MASS* (Venables & Ripley 2002), *car* (Fox & Weisberg 2019), *emmeans* (Lenth & Piaskowski 2026), *glmnet* (Friedman et al. 2010), *partykit* (Hothorn & Zeileis 2015, Hothorn et al. 2006, Zeileis et al. 2008), en *randomForest* (Liam & Wiener 2002).

Ik wil nog even benadrukken dat ik dit rapport in mijn vrije tijd gemaakt heb, op korte tijd, en tussen mijn reguliere werk door. Ik kan niet garanderen dat ik geen fouten gemaakt heb. Geen enkel onderzoek is vrij van kritiek. Reacties zijn welkom als ik me ergens vergist heb, maar ik hoop dat die reacties in alle redelijkheid gegeven worden. Op verschillende punten kan de analyse ongetwijfeld verder uitgediept of verfijnd worden, maar dat laat ik over aan anderen.

Ik hoop dat dit rapport een bijdrage kan leveren aan een meer geïnformeerd debat en een aanzet kan geven tot een grotere statistische geletterdheid van wie geïnteresseerd is in kwantitatieve data over maatschappelijke kwesties.

1 Beschrijving van de data

De data zijn door Profacts verzameld eind november, begin december 2025. De enquête is online afgenomen in het Nederlands, bij in totaal 2261 Vlamingen van 12 jaar en ouder. De gemiddelde invultijd bedroeg 10 minuten en 15 seconden. Alleen volledig ingevulde enquêtes zijn meegenomen in de analyse. De respondenten komen uit vooraf samengestelde panels, en ontvingen voor het invullen een aantal ‘punten’. Die punten kunnen ingeruild worden voor een waardebon of een bedrag dat aan een goed doel geschonken kan worden. Hoeveel punten een geënquêteerde verdient, hangt af van de lengte en moeilijkheid van de bevraging.

Profacts hanteert een dubbele kwaliteitscontrole, enerzijds op de samenstelling van het panel, door een zo representatief mogelijke spreiding over onafhankelijke variabelen zoals geslacht, provincie, leeftijd, opleidingsniveau na te streven, en anderzijds op het invullen van de vragen. Zo wordt er gecheckt op doublures, straightlining en op invulsnelheid. Details van deze kwaliteitscontroles kunnen geraadpleegd worden in het technisch rapport dat meegeleverd wordt bij de dataset op de hoger genoemde website, of bij Profacts zelf. Representativiteit van herkomstregio is notoir moeilijk, zeker als die variabele fijnmazig ingedeeld wordt (cf. infra). Maar het is nuttig op te merken dat zelfs bij een onderrepresentatie van een bepaalde categorie de data toch bruikbaar kunnen zijn. Een perfecte proportionele afspiegeling is een onhaalbaar ideaal.

Classificeren betekent moeilijke beslissingen nemen. Valt iemand die dertig jaar lang in Limburg gewoond heeft, maar recent verhuisd is naar Antwerpen, in de categorie ‘Limburger’ of in de categorie ‘Antwerpenaar’? Is een derde-generatie-immigrant een Belg of iemand met buitenlandse roots? Is iemand die in de bevraging aangeeft een Franse achtergrond te hebben een autochtone Fransman of iemand die uit Frankrijk komt maar daar Magrebijnse roots heeft? Hier moeten we ons neerleggen bij een mate van onzekerheid, maar zoals zal blijken uit de analyse, zien we toch een aantal trends die plausibel geduid kunnen worden. Voor de variabele geslacht of gender¹ is gewerkt met een binaire indeling ‘man’ vs. ‘vrouw’. Critici zouden kunnen opwerpen dat volledige representativiteit vereist dat ook mensen die niet binnen deze tweedeling vallen in de steekproef opgenomen moeten worden, maar de ervaring leert dat de aantallen vaak zo klein zijn dat het statistisch signaal verdwijnt.

Andere, bekende problemen zijn o.a. de mogelijkheid van selectiebias of sociale-wenselijkheidsbias: ongeletterde, zwakgeletterde of digitaal ongeletterde mensen zijn bijna automatisch uitgesloten van deelname, en mensen die deelnemen zullen wellicht niet altijd

¹ Ik ga hier niet in op de lastige afweging tussen geslacht, sekse en gender, en in welke mate dit een sociaal construct is, dan wel een biologische indeling.

eerlijk zijn, en mogelijk sociaal-wenselijke antwoorden geven (of omgekeerd, juist extremere antwoorden geven dan hun eigen overtuiging).

De meeste van deze problemen kunnen niet opgelost worden door geavanceerde statistiek van de dataset in zijn huidige vorm. Het adagium garbage-in-is-garbage-out is hier onverkort van kracht. Dit probleem is hoe dan ook moeilijk te vermijden, en het zou onredelijk zijn hier de enquêteurs te streng met de vinger te wijzen. Ik ga hier uit van het beginsel dat ik welwillend naar de aangeleverde data kijk, en aanneem dat die in eer en geweten verzameld zijn, en naar bestvermogen geclassificeerd zijn. De onvermijdelijke onzekerheid in de classificatie biedt ruimte voor reserves over de conclusies, maar het is mijn overtuiging dat de dataset zich qua kwaliteit moeiteloos kan meten met wat voorhanden is in veel academisch onderzoek. Een discussie ten gronde valt buiten het bestek van dit rapport.

2 Datavoorbewerking

2.1 Onafhankelijke variabelen

Als onafhankelijke variabelen zijn in deze analyse meegenomen: leeftijd, geslacht, opleidingsniveau en herkomstregio. Voor de eerste drie variabelen is de indeling gekozen die door de enquêteurs is aangebracht.²

Voor herkomst liggen de zaken wat complexer. In de dataset is een binaire categorische variabele voorhanden die een onderscheid maakt tussen autochtonen ($n = 1943$) en mensen met buitenlandse roots ($n = 310$).³ Die binaire variabele is wat minder gelukkig in te zetten voor onderzoek waar de herkomstregio van de respondent een 'variable of interest' vormt. In de publieke discussie is uitvoerig gewezen op de heterogene samenstelling van de groep 'buitenlandse herkomst', omdat hier mensen uit verschillende regio's samengenomen worden, zowel uit landen waarin de dominante cultuur sterk aanleunt bij de Vlaamse, bijvoorbeeld Nederlanders, als uit landen waarin de dominante cultuur er sterker van afwijkt, zoals bijvoorbeeld Sierra Leone.⁴

Er is in de dataset opvallenderwijze al een variabele voorhanden die al een classificatie maakt naar herkomstregio, en die niet uitgaat van een binair onderscheid, maar van de volgende levels: België, West-Europa, Zuid-Europa, Noord-Afrika/Midden-Oosten, Andere en Onbekend. Deze indeling vormt de basis voor de analyse van de factor herkomstregio in dit rapport, maar de moeilijkheid is dat elk level een aparte 'dummy variable' is in de dataset, en

² Voor meer details en de verdeling per categorie, zie het technisch rapport op de hoger genoemde website.

³ De oplettende lezer zal gemerkt hebben dat de som van 1943 en 310 niet 2261 (het totaal aantal respondenten) is, maar 2253. De reden is dat acht respondenten niet tot een van beide groepen gerekend konden worden, omdat de informatie niet voorhanden was.

⁴ Ideologisch geladen termen als 'dominante cultuur' worden hier louter als werkbare labels gebruikt. Ook hier is een discussie ten gronde over te houden, die ons ver buiten het bestek van dit rapport zou voeren.

een respondent bijvoorbeeld zowel West-Europeaan als Noord-Afrika/Midden-Oosten als herkomstregio kan hebben. De reden is dat respondenten meer dan een herkomstregio kon aangeven in de enquête, om de achtergrond van vader en moeder mee te nemen. Dit liet toe om tweedegeneratie-migranten niet blind toe te kennen aan de categorie: Belgische herkomstregio.

Voor de analyse in dit rapport is uitgegaan van een prioritering: Noord-Afrika-Midden-Oosten > Oost-Europees > Zuid-Europees > West-Europees > Andere > Belg. Dus als een respondent aangeeft als herkomstregio Noord-Afrika te hebben, dan komt die in die groep terecht, ook als diezelfde respondent bijvoorbeeld daarnaast Zuid-Europese of Belgische roots heeft.⁵ We hebben ook een aantal fout gecodeerde datapunten aangepast.⁶ De verdeling over de verschillende categorieën is als volgt:

Herkomstregio	n
Belgisch	1937
West-Europees	131
Oost-Europees	41
Zuid-Europees	21
Noord-Afrikaans & Midden-Oosten	45
Andere	72
Onbekend	14
Totaal	2261

Tabel 1: Herkomstregio

2.2 Afhankelijke variabelen

Zoals gezegd ligt de focus in dit rapport op de vragen die peilen naar tolerantie of acceptatie van gender-gerelateerde issues. Het gaat om de volgende stellingen of fictieve situaties in de enquête:

- Stellingen (zevenpuntenschaal “helemaal niet akkoord” – “helemaal akkoord”, met opties “Weet ik niet / geen mening” en “Ik antwoord hier liever niet op”)
 - *Ik vind het oké dat mensen in een holebi-relatie kinderen kunnen adopteren*

⁵ Deze – pragmatisch gemotiveerde – werkwijze is gevolgd op grond van overwegingen over migratie(geschiedenis): de hoger geprioriteerde groepen worden in Europees migratie- en diversiteitsonderzoek doorgaans als sociaal meer zichtbare en sterker gemarginaliseerde minderheidsgroepen beschouwd. Bijkomende ondersteuning komt van onderzoek naar WEIRD- en non-WEIRD-culturen (zie Henrich 2020).

⁶ Bijvoorbeeld respondent 285, die ‘Aghantan’ schrijft voor wat wellicht gelezen moeten worden als ‘Afghanistan’. Afghanistan is hier gerekend onder regio Noord-Afrika / Midden-Oosten. Daar valt het geografisch misschien niet helemaal onder, maar in cultuuronderzoek wordt het wel vaak samengenomen met deze regio.

- *Ik vind het belangrijk dat mensen qua geaardheid of gender (LGBTQI+) kunnen zijn wie ze zijn*
 - *Er zijn maar twee geslachten voor mij, man of vrouw*
 - *Ik zou een probleem hebben met homoseksuelen in mijn vriendengroep*
 - *Ik zou een probleem hebben met transgender personen in mijn vriendengroep*
 - *Voor mij moet het verboden worden dat mensen via een operatie kunnen veranderen van geslacht*
- Stellingen (drie opties: stelling links, midden, stelling rechts)⁷
- *Mannen en vrouwen zijn beide kostwinners binnen het gezin vs. Mannen moeten vooral de kostwinners zijn binnen het gezin.*
 - *Mannen en vrouwen zorgen samen voor de kinderen en de was en plas in het gezin. vs. Vrouwen zijn diegene die zorgen voor was en plas en opvoeden van de kinderen*
 - *Transgender personen zouden niet zo veel aandacht mogen krijgen. vs. Het is goed dat er aandacht is voor transgender personen*
 - *In de media is er te weinig aandacht voor LGBTQI+. vs. In de media is er te veel aandacht voor LGBTQI+.*
 - *Echtscheiding moet altijd mogelijk zijn. vs. Koppels mogen niet scheiden*
 - *Mannen hebben net iets meer te zeggen in een relatie dan vrouwen. vs. Mannen hebben in een relatie even veel te zeggen als vrouwen.*
- Fictieve situaties (opties: “Voor mij geen probleem”, “Ik vind dit niet oké”, “Geen mening”, “Ik antwoord hier liever niet op”):
- *Scholen willen volgend jaar lessen rond alle verschillende vormen van seksuele voorkeur.*
 - *Je kind komt thuis na school en zegt dat een vriendje twee papa’s of mama’s heeft*
 - *Je hebt een klasgenootje dat zegt dat hij twee papa’s of mama’s heeft (voor min-18-jarigen) of: Eén van je vrienden wil dat je in plaats van zij/hij de woorden die/hen zou gebruiken omdat die/hen zich noch man of vrouw voelt. (voor plus-18-jarigen in plaats van vorige vraag)*
 - *In steden heb je vaak een Pride, een jaarlijkse optocht van de LGBTQI+-gemeenschap.*
 - *Je komt te weten dat een mannelijke collega op het werk vroeger een vrouw was (alleen voor plus-18-jarigen)*

⁷ De stelling *Prostitutie moet kunnen vs. Prostitutie zou verboden moeten zijn* is niet meegenomen, omdat er in de literatuur over gender discussie is in welke richting we deze kwestie moeten interpreteren.

Al deze vragen zijn omgezet in een numerieke score van 0 tot 100, rekening houdend met de 'richting' van de antwoorden, zodat 0 overeenkomt met genderdiversiteitsonvriendelijkere attitudes en 100 met genderdiversiteitsvriendelijke attitudes. Antwoorden als "Weet ik niet / geen mening", "Ik antwoord hier liever niet op", zijn als NA gelabeld, en tellen dus niet mee. Voor de fictieve situaties is "Geen mening" geteld als 50 (maar "Ik antwoord hier liever niet op" als NA). Vervolgens is er een composietvariabele gemaakt, die alle scores bij elkaar neemt en herschaalt van 0 tot 100, waarbij op zijn minst 70% van de items beantwoord moet zijn. Anders wordt de respondent niet meegeteld.

Opnieuw ben ik hier pragmatisch tewerk gegaan. Zo zijn alle vragen gelijk gewogen, terwijl het even goed mogelijk is te argumenteren dat sommige stellingen informatiever zijn of sterker moeten doorwegen. Daar is van afgezien in dit rapport, om te vermijden dat er een subjectieve bias in de analyse komt. Het voordeel van te werken met een composiet-score is dat we een fijnkorrelige numerieke responsvariabele hebben, die statistisch krachtigere tests toelaat dan meer grofkorrelige binaire of ternaire indelingen. Het evidente nadeel is dat de score aggregeert over verschillende issues.

Een terechte vraag is dan of de verschillende stellingen of fictieve situaties hetzelfde onderliggende construct meten. Om dat na te gaan heb ik de interne consistentie gemeten van de variabelen die samengenomen zijn in de composietvariabele.⁸ Die is geruiststellend hoog (Cronbach's $\alpha = 0,89$; 95%-BI [0,88 ; 0,89]), een aanwijzing dat de items een coherent onderliggend construct benaderen. Geen van de items leidde bij verwijdering tot een substantiële verbetering van de betrouwbaarheid, waardoor alle items behouden bleven in de uiteindelijke schaalconstructie. De gemiddelde inter-itemcorrelatie bedroeg $r = 0,33$, wat wijst op een goede samenhang tussen de items zonder dat sprake is van overmatige redundantie.

3 Resultaten

3.1 Meervoudige regressie

Een voordehandliggende techniek om het verband te onderzoeken van herkomstregio, opleidingsniveau, geslacht en leeftijd op acceptatie of tolerantie voor gender-gerelateerde kwesties – ik zal voortaan gemakshalve spreken van 'gendertolerantie' – is meervoudige lineaire regressie met de composietvariabele als respons. Omdat er voor sommige waarden een relatief beperkt aantal datapunten voorhanden is, modelleer ik voor dit rapport geen interactie-effecten, maar beperk ik me tot multivariaat gecontroleerde hoofdeffecten. Leeftijd

⁸ De vraag "Je komt te weten dat een mannelijke collega op het werk vroeger een vrouw was" is voor het vaststellen van consistentie geschrapt voor de analyse, omdat ze niet aan de respondenten jonger dan 18 is voorgelegd. Als de vraag meegerekend wordt, verschillen de resultaten niet wezenlijk: Cronbach's $\alpha = 0,90$; 95%-BI [0,89 ; 0,90]. Inter-itemcorrelatie $r = 0,33$.

is behandeld als categorische variabele, niet als numerieke variabele, om niet-lineaire effecten op te vangen.^{9, 10} Dat levert deze resultaten op:¹¹

Variabele	Waarde	Coëfficiënt	Standaardfout	t-waarde	p-waarde
(as-afsnede)		57,18	1,71	33.42	< 0,0001
Herkomst	Belgisch	(ref.)	-	-	-
	West-Eur.	-4,35	1,83	-2.38	< 0,05
	Zuid-Eur.	-12,27	4,30	-2,85	< 0,01
	Oost.Eur.	-9,00	3,20	-2,81	<0,01
	N.-Afrika / Midden-O.	-15,54	3,09	-5,03	< 0.0001
	Andere	-5,73	2,41	-2,38	< 0,05
	Onbekend	-14,49	6,38	-2,27	< 0,05
Geslacht	man	(ref.)	-	-	-
	vrouw	9,50	0,83	11,40	< 0,0001
Leeftijd	12-17	1,47	2,51	0,59	n.s.
	18-24	-3,32	1,84	-1,80	n.s. (< 0,1)
	25-34	-3,51	1,52	-2.30	< 0,05
	35-44	(ref.)	-	-	-
	45-54	5,25	1,51	3,47	< 0,001
	55-64	5,82	1,47	3,94	< 0,0001
	65+	5,33	1,36	3,91	< 0,0001
Opleidingsniveau	(1-10)	1,07	0,21	5,11	< 0,0001

Tabel 2: Output lineair regressiemodel Gendertolerantie ~ Herkomstregio + Geslacht + Leeftijd + Opleidingsniveau (p-waarde van het totale model < 0,0001)

Het model verklaart 13% van de variantie (model-R²), wat betekent dat er veel variatie niet gevat wordt met deze set variabelen, en dat binnen de categorieën mensen zeker niet homogeen zijn in hun opvattingen. Niettemin is er een duidelijk signaal te ontwaren. Niet alles is ruis. En voor attitude-onderzoek met een beperkte set variabelen, is 13% niet uitzonderlijk laag. Vrouwen zijn bijna tien procentpunten gender-toleranter dan mannen, en afgezien van de groep 12- tot 17-jarigen, zien we dat respondenten jonger dan 35 gender-intoleranter zijn dan de middengroep (35-jarigen tot 44-jarigen), al is het verschil hier niet significant op het niveau van 0,05 voor de groep 18-24, en dat respondenten ouder dan 44 gender-toleranter zijn dan de middengroep. Als we opleidingsniveau in tien trappen verdelen, dan zien we dat bij het stijgen van een trap de gendertolerantie met 1 procentpunt stijgt. Verder is er ook een


⁹ Gezien het ordinale karakter van deze variabele had hier in principe ook gekozen kunnen worden voor Helmert-coding.

¹⁰ De hier gerapporteerde effecten van herkomstregio, geslacht en opleidingsniveau, verschillen niet wezenlijk in aard, effectgrootte, richting of significantie als wanneer leeftijd numeriek geschaald wordt.

¹¹ 167 respondenten zijn weggevallen uit de regressieanalyse door 'missingness'. Die vallen ook weg voor de analyse in 3.2. Vooral in de leeftijdscategorie 12-17-jarigen is er uitval.

effect van herkomstregio, waarbij onder multivariate controle de tolerantie afneemt volgens het continuüm Belgisch < West-Europees < Andere < Oost-Europees < Zuid-Europees < Onbekend < Noord-Afrika / Midden-Oosten. Mensen met roots in Noord-Afrika of het Midden-Oosten scoren 15 procentpunten lager dan de autochtone Belgen op gendertolerantie. Opvallend is ook de uitgesproken lagere score voor Zuid-Europeanen. Een Tukey-post-hocanalyse van de geschatte marginale gemiddelden wees verder uit dat respondenten met een Noord-Afrikaanse of Midden-Oosterse herkomst significant lager scoorden op de inclusiviteitsindex dan respondenten met een Belgische herkomst ($p < 0,0001$) en een West-Europese herkomst ($p < 0,05$).¹²

Voor de regressieanalyse zijn een aantal tests uitgevoerd die de modelassumpties nagaan. Multicollineariteit is getest aan de hand van de variantie-inflatiefactoren. Er werden geen aanwijzingen gevonden voor problematische multicollineariteit.¹³ Diagnostische plots (zie Figuur 1) geven geen aanwijzingen voor ernstige schendingen van lineariteit of homoskedasticiteit.




Figuur 1: Diagnostische plots voor het regressiemodel

¹² Deze test is strenger doordat ze met een correctie voor meervoudige testing werkt.

¹³ Alle $\text{GVIF}^{1/(2 \cdot \text{Df})}$ -waarden lagen dicht bij 1.

Een zogeheten ‘invloedplot’ (Figuur 2) visualiseert de hefboom-waarden (‘hat values’), gestudentiseerde residuen en de Cook-afstanden. Van belang zijn vooral de Cook-afstanden, die weergeven hoe groot het effect op de regressiecoëfficiënten is als die observatie weggehaald wordt. De Cook-afstanden worden weergegeven door de omvang van de bubbels en de kleur (intensiteit blauw). Er zijn twee opmerkelijke datapunten: respondent 1811 en respondent 1521. Respondent 1811 is een vrij hoogopgeleide vrouw van 25-34 jaar, met een herkomstregio ‘onbekend’, die een hoge score heeft op gendertolerantie (97,2/100). Respondent 1521 is een vrij hoog opgeleide vrouw van 55-64 jaar, herkomstregio ‘onbekend’, die een lage score heeft op gendertolerantie (28,2/100). Al bij al laat het invloedplot zien dat het regressiemodel niet erg scheefgetrokken wordt door een aantal al te problematische datapunten.



Figuur 2: Invloedplot

Op het regressiemodel is ook een variabeleselectieprocedure toegepast. Een tweerichtingsprocedure aan de hand van het Akaike Informatiecriterium (AIC), die een optimale balans probeert te vinden tussen de verklarende kracht van het model en de spaarzaamheid, laat zien dat alle bovenstaande variabelen behouden blijven.

Om overfitting te beperken en de meest predictieve variabelen te identificeren, werd een LASSO-regressie uitgevoerd. De optimale regularisatieparameter (λ_{1se}) werd

bepaald met tienvoudige kruisvalidatie, waarbij gebruik werd gemaakt van een Gaussiaans lineair model.

De variabelen geslacht, herkomstregio, leeftijd en enkele opleidingscategorieën zijn als relevante predictoren behouden voor gendertolerantie. De richting en effectgrootte van de onafhankelijke variabelen van het eerder gerapporteerde regressiemodel bleven overeind. Verschillende categorieën werden door de regularisatieprocedure naar nul gereduceerd, wat erop wijst dat zij weinig bijkomende predictieve waarde toevoegden aan het model. Het gaan dan over een de categorie 12-17-jarigen en een aantal opleidingsniveaus.

3.2 Conditionele boom en random woud


Een regressiemodel is een parametrische techniek. Er zijn ook niet-parametrische technieken om een beeld te krijgen van het effect van de predictoren. Om interacties en subgroepsverschillen in gendertolerantie te onderzoeken heb ik een conditionele inferentieboom (ctree) geschat. Als predictoren zijn dezelfde variabelen gebruikt als in het hogerop gerapporteerde regressiemodel: gender, leeftijd, opleidingsniveau en herkomstregio.

Zoals blijkt uit Figuur 3 is de hoogste splitsing die voor de factor gender ($p < 0,001$), die de vaststelling in de regressieanalyse bevestigt dat vrouwen hoger scoren op gendertolerantie.¹⁴ Binnen de groep mannen is leeftijd de belangrijkste verdere differentiatie ($p < 0,001$). De boomanalyse vertoont een patroon dat grotendeels consistent is met de regressieresultaten: jongere leeftijdsgroepen vertonen gemiddeld lagere scores dan oudere leeftijdsgroepen. Daaronder zit een differentiatie op opleidingsniveau, waarbij lagere opleidingsniveaus ook een minder gendertolerante score laten optekenen.

Binnen de groep vrouwen bleek herkomstregio de belangrijkste verdere differentiatie te zijn ($p < 0,001$). Vrouwen met een Belgische, West-Europese (of 'andere') herkomst hebben gemiddeld hogere inclusiviteitsscores dan vrouwen met een Zuid-Europese, Oost-Europese, MENA (of 'onbekende') achtergrond. Binnen die eerste groep is er nog een verdere differentiatie op opleidingsniveau ($p < 0,001$).


Voor de conditionele inferentieboom is een versie gemaakt met kruisvalidatie (80% trainingsdata, 20% testdata). De predictieve performantie van deze boom was matig ($r = 0,33$ tussen voorspelde en geobserveerde waarden in de test-set). Dat suggereert dat de opgenomen socio-demografische variabelen een betekenisvol maar beperkt deel van de variantie in gendertolerantie verklaren. De verklaarde variantie van 11% zit in dezelfde bandbreedte als die van het regressiemodel.

¹⁴ De tekst in de boom is klein gedrukt, omdat anders sommige labels in verschillende takken anders in elkaars vaarwater kwamen. Om de leesbaarheid te vergroten is met afkortingen gewerkt. De meeste afkortingen spreken voor zich. Voor de waarde 'Noord-Afrika / Midden-Oosten' van de variabele Herkomstregio is hier de gebruikelijke Engelse afkorting MENA (Middle East and North Africa) gehanteerd.



Figuur 3: Conditionele inferentieboom

Ten slotte is de analyse ook nog uitgebreid met een random woud gebouwd, met 5000 bomen. Dit model verklaart ongeveer 14% van de variantie in gendertolerantie, op basis van de out-of-bag-voorspelfout. Dat is iets meer dan de conditionele inferentieboom, die typisch vrij conservatief is. Variabele-belang-analyse (%IncMSE) wees uit dat geslacht de sterkste predictor was, gevolgd door leeftijdscategorie, opleidingsniveau en herkomstregio. De laatste twee variabelen liggen dicht bij elkaar, qua belang.



Figuur 4: Variabele-belang van het random woud

4 Conclusie

De analyse van de dataset van *Foto van Vlaanderen* laat zien dat het vernietigende verdict dat links en rechts werd uitgevaardigd over de mogelijkheid enig signaal te ontwaren in het effect van socio-demografische variabelen op de attitudes inzake gendertolerantie niet helemaal gerechtvaardigd was. De data zijn niet ideaal, maar zeker ook niet waardeloos. Hoewel een en ander met de nodige omzichtigheid benaderd moet worden – zoals trouwens gebruikelijk is met het meeste, zo niet al het kwantitatieve onderzoek – valt toch op basis van de verzamelde gegevens te zeggen dat er significante associaties zijn tussen gendertolerantie-attitudes en leeftijd, geslacht, opleidingsniveau en herkomstregio. Met name die laatste variabele is het voorwerp van nogal wat discussie geweest. De regressieanalyse en conditionele inferentieboom laten een vrij aanzienlijk verschil optekenen tussen autochtone Belgen en West-Europeanen enerzijds en Oost-Europeanen, Zuid-Europeanen en Noord-Afrikanen en mensen uit het Midden-Oosten anderzijds.

We moeten ons ervoor hoeden hier causale interpretaties aan te geven, want de analyse is gebaseerd op cross-sectionele surveydata. Voor sterkere causale identificatie zijn andere onderzoeksdesigns nodig, zoals longitudinale analyses, experimentele of quasi-experimentele methoden, of expliciete causale modelleringsstrategieën op basis van bijvoorbeeld directed acyclic graphs (DAGs, zie Pearl 2009 en Pearl & Mackenzie 2018). Structurele-equatiemodellen (SEM) kunnen daarbij nuttig zijn om complexe theoretische verbanden en latente constructen te modelleren, maar die leveren op zichzelf geen bewijs voor causaliteit.

Aangehaalde literatuur

- Fox J. & S. Weisberg. 2019. *An R Companion to Applied Regression*. 3e ed. Thousand Oaks: Sage.
- Friedman J., R. Tibshirani & T. Hastie. 2010. 'Regularization paths for generalized linear models via coordinate descent'. *Journal of Statistical Software* 33(1): 1-22.
- Henrich, J. 2020. *The WEIRDest people in the world. How the West became psychologically peculiar and particularly prosperous*. New York: Farrar, Straus & Giroux
- Hothorn T., A. Zeileis. 2015. 'partykit: a modular toolkit for recursive partytioning in R.' *Journal of Machine Learning Research* 16: 3905-3909.
- Hothorn T., K. Hornik & A. Zeileis. 2006. 'Unbiased recursive partitioning: a conditional inference framework'. *Journal of Computational and Graphical Statistics* 15(3): 651-674.
- Lenth R. & J. Piaskowski. 2026. *emmeans: estimated marginal means, aka least-squares means*. R package version 2.0.3.
- Liaw A. & M. Wiener. 2002. 'Classification and regression by randomForest'. *R News* 2(3): 18-22.

- Pearl, J. 2009. *Causality: models, reasoning, and inference*. 2e ed. Cambridge: Cambridge University Press.
- Pearl, J. & D. Mackenzie. 2018. *The book of why: the new science of cause and effect*. New York: Basic Books.
- Revelle, W. 2026. *psych: procedures for psychological, psychometric, and personality research*. Northwestern University, Evanston, Illinois. R package, versie 2.6.4.
- Venables, W.N. & B.D. Ripley. 2002. *Modern applied statistics with S*. 4e ed. New York: Springer.
- Wickham H., R. François, L. Henry, K. Müller & D. Vaughan. 2023. *dplyr: a grammar of data manipulation*. R package versie 1.1.4.
- Zeileis A., T. Hothorn & K. Hornik. 2008. 'Model-based recursive partitioning'. *Journal of Computational and Graphical Statistics* 17(2): 492-514.